
Taller — Predicción de Accidentalidad

Clasificación binaria · Clases desbalanceadas · Datos en SQLite

Autores:

Juan Pablo Rúa · Juan Pablo Mejía
Fredy Cadavid · Pedro Saldarriaga

Aprendizaje Automático · MCDA 2026-1 · Universidad EAFIT

Profesor: Pablo Saldarriaga / Marco Terán

Mayo 2026

Tema:	Predicción de accidentalidad por barrio y hora
Modalidad:	Grupal
Entregables:	Informe en PDF + Notebook (.ipynb)
Período de datos:	2017–2019 (Medellín)

Índice

1. Resumen ejecutivo	4
2. Descripción del problema y de los datos	4
2.1. Contexto del problema	4
2.2. Fuente de datos	4
2.3. Construcción de la variable objetivo	5
2.4. Estadísticas del dataset	5
3. Análisis exploratorio de datos	5
3.1. Distribución temporal	5
3.2. Distribución espacial	6
3.3. Caracterización del clima	7
3.4. Calidad de datos	7
3.4.1. Nulos detectados	7
3.4.2. Duplicados	8
3.4.3. Consistencia entre tablas	8
4. Ingeniería de características	8
4.1. Unión de tablas	8
4.2. Variables creadas	8
4.2.1. Variables climáticas (11)	8
4.2.2. Variables temporales lineales (6)	8
4.2.3. Variables binarias (4)	9
4.2.4. Variables cíclicas seno/coseno (8)	9
4.2.5. Variables históricas — target encoding sin data leakage (3)	9
4.2.6. Frequency encodings (4)	9
5. Modelado	10
5.1. Baseline ingenuo: por qué la accuracy no sirve	10
5.2. Estrategias de balanceo	10
5.3. Comparación de familias de modelos	11

5.4. Ajuste de hiperparámetros	11
6. Métricas y selección del modelo final	12
6.1. Curvas de evaluación en VAL	12
6.2. Importancia de variables	13
6.3. Selección del umbral de decisión	14
6.4. Evaluación final en TEST	14
6.4.1. Interpretación de las matrices de confusión	15
6.5. Justificación del modelo final	16
7. Validación	16
7.1. Estrategia de validación temporal	16
7.2. Validación cruzada en el tuning	17
7.3. Estabilidad entre val y test	17
8. Caso de uso y limitaciones	17
8.1. Propuesta operacional: mapa de calor de riesgo	18
8.2. Limitaciones del modelo	18
8.3. Variables externas que mejorarían el modelo	19
9. Conclusiones y trabajo futuro	19
9.1. Conclusiones	19
9.2. Trabajo futuro	20

1 Resumen ejecutivo

Se construyó un modelo de clasificación binaria para predecir si ocurrirá al menos un accidente de tránsito en un barrio de Medellín a una hora determinada del día. El dataset contiene 7.991.780 observaciones correspondientes a todas las combinaciones barrio $\times$ hora del período 2017–2019, de las cuales solo el **1.507%** registra un accidente (120.475 positivos).

El modelo final es un **HistGradientBoosting ajustado con undersampling 3:1**, seleccionado por su equilibrio entre PR-AUC, velocidad de entrenamiento y capacidad de generalización. Con un umbral de decisión optimizado por función de costo asimétrica ($FN = 10\times$, $FP = 1\times$), el umbral resultante es **0.700**, con el que el modelo alcanza en el conjunto de prueba un ROC-AUC de 0.8059 y un PR-AUC de 0.0801 — más de $5\times$ el baseline aleatorio (0.015).

El caso de uso propuesto es un **mapa de calor diario de riesgo** que permite a la Secretaría de Movilidad priorizar operativos preventivos en los barrios y franjas horarias de mayor probabilidad predicha.

2 Descripción del problema y de los datos

2.1 Contexto del problema

Las administraciones municipales necesitan anticipar dónde y cuándo es más probable que ocurra un accidente de tránsito para focalizar operativos, agentes y campañas de prevención. El reto no es trivial: la mayoría de las combinaciones (barrio, hora) no presentan accidentes, y solo una pequeña fracción sí los registra. En otras palabras, el problema es *por naturaleza* un problema de clases desbalanceadas.

Pregunta a responder

¿Cuál es la probabilidad de que ocurra al menos un accidente en el barrio B a la hora h del día?

2.2 Fuente de datos

La base de datos SQLite contiene tres tablas:

- **raw_accidentes:** 125.122 filas. Información detallada de cada accidente reportado. Período: 2017-01-01 a 2019-12-31.
- **accidentes:** 120.587 filas. Versión agregada: indica que existió al menos un accidente en (barrio, hora). Es la fuente natural de los *casos positivos*.

- **clima:** 7.991.780 filas. Mediciones meteorológicas por barrio y hora — cubre **todas** las combinaciones (barrio, hora) y es la base para construir los casos negativos.

2.3 Construcción de la variable objetivo

1. **Unidad de análisis:** cada fila es una combinación única (BARRIO, TW) donde TW es la marca temporal truncada a la hora.
2. **Casos negativos:** la tabla `clima` cubre todas las combinaciones. Se hace un *left join* de `clima` con `accidentes`: si la pareja (BARRIO, TW) está en `accidentes`, `target = 1`; de lo contrario, `target = 0`.
3. **Proporción de la clase positiva:** 120.475 positivos sobre 7.991.780 observaciones = **1.507 %**. Este desbalance extremo motiva todo el trabajo metodológico posterior.

2.4 Estadísticas del dataset

Cuadro 1: Resumen del dataset unificado

Split	Filas	% Positivos
Train (hasta 2018-06-30)	4.037.470	1.48 %
Val (2018-07-01 a 2018-12-31)	1.343.830	1.47 %
Test (2019-01-01 a 2019-12-31)	2.610.480	1.57 %
Total	7.991.780	1.507 %

3 Análisis exploratorio de datos

3.1 Distribución temporal




Figura 1: Distribución temporal de accidentes: por hora del día (izquierda), día de la semana (centro) y mes (derecha).

Los patrones temporales revelan:

- **Hora del día:** existe un patrón bimodal de movilidad. Se observa un pico pronunciado entre las 16h y las 18h (máximo absoluto: ≈ 8.700 accidentes a las 17h), con un pico menor en las horas de mañana (7h–9h). Las madrugadas (0h–4h) concentran el menor número de accidentes.
- **Día de la semana:** los días hábiles (martes y viernes son los más críticos) presentan mayor accidentalidad. El domingo es claramente el día de menor riesgo (≈ 11.000 accidentes vs. ≈ 18.000 el martes).
- **Mes:** la distribución mensual es relativamente homogénea a lo largo del año, con algo más de accidentalidad en el segundo semestre (agosto–octubre). No existe estacionalidad muy marcada.

Estos patrones justifican directamente las variables temporales creadas en la ingeniería de características: hora del día, día de la semana, mes, bandera de hora pico, bandera de fin de semana y festivo.

3.2 Distribución espacial




Figura 2: Top 20 barrios con mayor número de accidentes acumulados (2017–2019).

La accidentalidad está fuertemente concentrada en pocos barrios. Los diez barrios más peligrosos concentran una fracción desproporcionada de los accidentes:

- **La Candelaria** lidera con ≈ 2.750 accidentes, seguido de **Campoamor** (≈ 2.500) y **Perpetuo Socorro** (≈ 2.300).
- También destacan: Caribe, Barrio Colón, Santafé, Los Conquistadores y Villanueva.
- Esta concentración espacial es la señal más fuerte del problema y explica por qué las tasas históricas por barrio son las variables más informativas del modelo.

3.3 Caracterización del clima

Las variables climáticas fueron inspeccionadas en búsqueda de correlación con la accidentalidad. Medellín tiene un clima tropical con variaciones relativamente moderadas (temperatura media 17–25°C, precipitación intermitente). El análisis de importancia de variables (Sección 6.2) confirma que el clima aporta marginalmente al modelo frente a las tasas históricas de barrio y las variables temporales.

3.4 Calidad de datos

3.4.1 Nulos detectados

Cuadro 2: Nulos en la tabla clima

Variable	Nulos	%
windBearing	1.032.513	12.92 %
summary / icon	548.641	6.87 %
precipIntensity / precipProbability	547.401	6.85 %
windSpeed	32.793	0.41 %
cloudCover	7.950	0.10 %
uvIndex	4.280	0.05 %
visibility	4.290	0.05 %
temperature / apparentTemperature	610	0.01 %
humidity	915	0.01 %
dewPoint	305	0.00 %
accidentes	Sin nulos	

Los nulos más relevantes son **windBearing** (12.9 %) y el bloque **precip** (~ 7 %). En ambos casos se imputan con la mediana de la variable (para numéricas) y con la categoría ‘desconocido’ (para **summary** e **icon**). Los modelos basados en árboles (Random Forest y HistGB) toleran nulos nativamente, lo que reduce el impacto práctico.

3.4.2 Duplicados

Cero duplicados en la clave (BARRIO, TW) tanto en **accidentes** como en **clima**. Esto garantiza que el join produce exactamente una fila por combinación.

3.4.3 Consistencia entre tablas

- **raw_accidentes**: 322 barrios únicos.
- **accidentes**: 322 barrios únicos.
- **clima**: 319 barrios únicos.
- 3 barrios aparecen en **accidentes** pero no en **clima**, lo que implica la pérdida de 4 accidentes (0.003 % del total). Pérdida despreciable; se acepta y documenta.

Todos los nombres de barrios fueron normalizados a minúsculas y sin espacios adicionales en las tres tablas antes del join, evitando fallos silenciosos por diferencias de formato.

4 Ingeniería de características

4.1 Unión de tablas

Se realizó un **left join** de **clima** (tabla base, 7.991.780 filas) con **accidentes** sobre las claves (BARRIO, TW). Este tipo de join preserva todas las combinaciones barrio × hora de la tabla **clima** (incluyendo las que no tienen accidente) y asigna **target=1** únicamente donde hay coincidencia con **accidentes**. El resultado es el dataset de modelado completo con la variable objetivo binaria construida correctamente.

4.2 Variables creadas

Se generaron **36 features** organizadas en cinco grupos:

4.2.1 Variables climáticas (11)

Temperature, apparentTemperature, dewPoint, humidity, precipIntensity, precipProbability, windSpeed, windBearing, cloudCover, uvIndex, visibility. Tomadas directamente de la tabla **clima**, con imputación de nulos por mediana de train.

4.2.2 Variables temporales lineales (6)

hora, dia_semana, mes, dia_del_anio, anio, dia_del_mes. Extraídas de la columna TW.

4.2.3 Variables binarias (4)

- **es_fin_semana:** 1 si sábado o domingo.
- **es_hora_pico:** 1 si hora $\in \{7,8,16,17,18\}$ (validado con EDA).
- **es_madrugada:** 1 si hora $\in \{0,1,2,3,4\}$.
- **es_festivo:** 1 si la fecha es festivo oficial colombiano.

4.2.4 Variables cíclicas seno/coseno (8)

Para capturar la continuidad cíclica (la hora 23 y la hora 0 son consecutivas, pero numéricamente están lejos), se codifican cuatro variables con sus componentes seno y coseno:

$$x_{\sin} = \sin\left(\frac{2\pi \cdot x}{T}\right), \quad x_{\cos} = \cos\left(\frac{2\pi \cdot x}{T}\right) \quad (1)$$

donde T es el período correspondiente (24 para hora, 7 para día de la semana, 12 para mes, 365 para día del año). Esto genera los pares: hora_sin/cos, dia_semana_sin/cos, mes_sin/cos, dia_del_anio_sin/cos.

4.2.5 Variables históricas — target encoding sin data leakage (3)

Estas son las variables más informativas del modelo. Se calculan **exclusivamente con el conjunto de train** y se mapean a val y test:

- **tasa_acc_barrio:** $P(\text{accidente} \mid \text{barrio})$ — proporción histórica de horas con accidente por barrio.
- **tasa_acc_barrio_hora:** $P(\text{accidente} \mid \text{barrio}, \text{hora})$ — la señal más fuerte.
- **tasa_acc_barrio_dia:** $P(\text{accidente} \mid \text{barrio}, \text{día_semana})$.

Para barrios o combinaciones no vistas en train, el valor por defecto es la media global de train (1.482 %), sin usar ninguna información de val o test.

4.2.6 Frequency encodings (4)

Para las variables categóricas BARRIO, summary, icon y COMUNA, se usa *frequency encoding*: cada valor se reemplaza por su frecuencia relativa en train. Esta técnica es compacta (una columna por variable vs. 322 columnas con one-hot para BARRIO) y respeta el principio de no leakage. Rangos resultantes:

- barrio_freq: [0.00000, 0.00324]

- summary_freq: [0.00000, 0.38364]
- icon_freq: [0.00001, 0.36482]
- comuna_freq: [0.00217, 0.07783]

5 Modelado

5.1 Baseline ingenuo: por qué la accuracy no sirve

Antes de entrenar ningún modelo, se evalúa el predictor trivial que predice siempre la clase mayoritaria (0 = sin accidente):

Cuadro 3: Métricas del baseline ingenuo (predecir siempre 0)

Métrica	Valor
Accuracy	0.9853
Precision	0.0000
Recall	0.0000
F1-score	0.0000

Un 98.5 % de accuracy *sin detectar ningún accidente* demuestra por qué esta métrica es inútil en problemas con desbalance fuerte. Las métricas seleccionadas son **PR-AUC** (métrica principal), ROC-AUC, F1, Precision y Recall.

5.2 Estrategias de balanceo

Para aislar el efecto del balanceo del efecto del modelo, se fijó un modelo base (Regresión Logística) y se compararon tres estrategias sobre el conjunto de validación:

Cuadro 4: Comparación de estrategias de balanceo (LR, evaluado en VAL)

Estrategia	PR-AUC	Recall	Tiempo (s)
Sin balanceo	0.0756	0.0003	12.4
class_weight='balanced'	0.0753	0.6118	21.5
Undersampling 3:1	0.0755	0.3308	2.4

Hallazgo clave: el PR-AUC es prácticamente idéntico entre las tres estrategias porque mide la calidad del *ranking de probabilidades*, no la clasificación binaria con umbral fijo. La diferencia relevante está en el recall con umbral 0.5. Se selecciona **undersampling 3:1** por tres razones:

1. Es $\approx 20\times$ más rápido que entrenar con el dataset completo ($\rightarrow$ facilita reentrenamientos periódicos en producción).
2. Mantiene el desbalance real, sin eliminar la señal de la clase mayoritaria.
3. No sintetiza datos artificiales (SMOTE en eventos raros puede generar puntos no representativos).

El conjunto de entrenamiento balanceado contiene: 59.852 positivos + 179.556 negativos = **239.408 filas totales**.

5.3 Comparación de familias de modelos

Usando el mismo train balanceado (undersampling 3:1), se comparan tres familias:

Cuadro 5: Comparación de modelos en VAL (umbral = 0.5)

Modelo	PR-AUC	F1	ROC-AUC	Recall	Tiempo (s)
Random Forest	0.0792	0.1296	0.8198	0.4323	11.5
HistGradientBoosting	0.0768	0.1214	0.8141	0.4555	71.5
Regresión Logística	0.0755	0.1426	0.8023	0.3308	2.5

Interpretación: las tres familias tienen PR-AUC similar (~ 0.076 – 0.079), lo que indica que el techo del problema está determinado por las features, no por el algoritmo. Se elige **HistGradientBoosting** como modelo a ajustar por: soporte nativo de early stopping, manejo de valores faltantes sin imputación explícita, y mejor equilibrio recall/precision ajustable.

5.4 Ajuste de hiperparámetros

Se realizó **RandomizedSearchCV** con 8 iteraciones, **TimeSeriesSplit(3)** (respeta el orden temporal) y scoring **average_precision** (PR-AUC). El espacio de búsqueda fue diseñado con sesgo anti-sobreajuste:

Cuadro 6: Espacio de búsqueda y mejores hiperparámetros encontrados

Hiperparámetro	Espacio	Mejor valor
learning_rate	Uniforme(0.02, 0.10)	0.02451
max_iter	Entero(150, 350)	307
max_depth	Entero(4, 8)	7
min_samples_leaf	Entero(30, 100)	93
l2_regularization	Uniforme(0.0, 3.0)	1.953
max_leaf_nodes	Entero(15, 50)	16

El mejor PR-AUC en CV fue 0.6182 (sobre el sub-conjunto balanceado de tuning). Tras re-entrenar con todo el train balanceado, el modelo tuned alcanza en VAL: PR-AUC=0.0784, F1=0.1238. La ganancia sobre el modelo no tuneado es modesta, lo que indica que ya estábamos cerca del techo del modelo base.

6 Métricas y selección del modelo final

6.1 Curvas de evaluación en VAL




Figura 3: Curvas Precision-Recall (izquierda) y ROC (derecha) en VAL para los cuatro modelos. El baseline de PR-AUC = 0.015 corresponde a la proporción de positivos.

Las curvas muestran que todos los modelos entrenados superan claramente el baseline aleatorio. La curva PR muestra la característica forma descendente propia de datasets desbalanceados: con umbrales bajos se detecta una fracción grande de accidentes (alto recall) a costa de muchas falsas alarmas (baja precision). La curva ROC con $AUC \approx 0.82$ indica buena capacidad discriminativa global.

6.2 Importancia de variables




Figura 4: Importancia por permutación (caída en PR-AUC al permutar) del modelo HistGB tuned.

El gráfico de importancia por permutación es contundente: las **tasas históricas por barrio dominan** la señal predictiva.

- **tasa_acc_barrio_hora:** 0.063 (por lejos la más importante — captura el patrón histórico de riesgo por barrio y franja horaria).
- **tasa_acc_barrio_dia:** 0.034 (segundo lugar — patrón por barrio y día de la semana).
- **tasa_acc_barrio:** 0.006 (riesgo base del barrio).
- **dia_semana:** 0.004, **es_festivo:** 0.004.
- Variables climáticas: contribución marginal (<0.002 cada una). Esto es coherente con el clima relativamente estable de Medellín.

6.3 Selección del umbral de decisión




Figura 5: Izquierda: métricas (Precision, Recall, F1) en función del umbral. Derecha: función de costo total ($FN=10\times$, $FP=1\times$) en función del umbral.

Se identifican dos umbrales de interés:

1. **Umbral por F1 óptimo:** 0.676 — maximiza el F1-score (equilibrio precision/recall).
2. **Umbral por costo asimétrico:** 0.700 — minimiza la función de costo $C = 10 \cdot FN + 1 \cdot FP$. La razón 10:1 refleja que no detectar un accidente (FN) tiene un costo operacional y social mucho mayor que enviar un agente innecesariamente (FP).

Se selecciona el **umbral por costo (0.700)** como umbral final por estar alineado con la métrica de negocio.

6.4 Evaluación final en TEST

Métricas en TEST — Modelo final: HistGB tuned + undersampling 3:1		
	Métrica	Valor
	PR-AUC	0.0801
	ROC-AUC	0.8059
	Precision (umbral 0.700)	0.1204
	Recall (umbral 0.700)	0.2046
	F1-score (umbral 0.700)	0.1516




Figura 6: Matrices de confusión en TEST: umbral por costo = 0.700 (azul) y umbral por F1 = 0.676 (naranja).

6.4.1 Interpretación de las matrices de confusión

Cuadro 7: Matriz de confusión — Umbral por costo (0.700) en TEST

	Pred. 0	Pred. 1
Real 0	2.508.523 (TN)	61.088 (FP)
Real 1	32.509 (FN)	8.360 (TP)

Cuadro 8: Matriz de confusión — Umbral por F1 (0.676) en TEST

	Pred. 0	Pred. 1
Real 0	2.493.347 (TN)	76.264 (FP)
Real 1	31.106 (FN)	9.763 (TP)

Con el umbral de costo, el modelo detecta **8.360 combinaciones (barrio, hora) con accidente** que de otro modo no se habrían priorizado, a costa de 61.088 falsas alarmas. Con el umbral F1, detecta 9.763 TP con más falsas alarmas (76.264 FP). El umbral de costo es preferible en el contexto operacional porque minimiza los falsos negativos.

6.5 Justificación del modelo final

Cuadro 9: Comparación final de todos los modelos evaluados en VAL

Modelo	PR-AUC	ROC-AUC	F1	Recall	Tiempo (s)
LR sin balanceo	0.0756	0.8023	0.0003	0.0001	12.4
LR class_weight	0.0753	—	0.1426	0.6118	21.5
LR undersampling 3:1	0.0755	0.8023	0.1426	0.3308	2.5
RF undersampling 3:1	0.0792	0.8198	0.1296	0.4323	11.5
HistGB undersampling 3:1	0.0768	0.8141	0.1214	0.4555	71.5
HistGB tuned	0.0784	~0.815	0.1238	—	—

Se selecciona **HistGradientBoosting tuned con undersampling 3:1** por:

- Mayor PR-AUC y ROC-AUC entre los modelos finales evaluados.
- Soporte nativo de early stopping (evita sobreajuste automáticamente).
- Manejo interno de valores faltantes.
- Hiperparámetros conservadores que priorizan generalización sobre ajuste al train.
- Compatible con reentrenamiento frecuente (importante para mitigar deriva temporal).

7 Validación

7.1 Estrategia de validación temporal

La validación principal es la **partición temporal estricta**:

- **Train** (hasta 2018-06-30): 4.037.470 filas — usado para ajustar modelos y calcular features históricas.
- **Val** (2018-07-01 a 2018-12-31): 1.343.830 filas — usado para seleccionar el modelo y el umbral.
- **Test** (2019-01-01 a 2019-12-31): 2.610.480 filas — evaluación final, consultado *una sola vez* al final.

Esta partición simula el uso real del modelo: siempre se predice el futuro con información del pasado.

7.2 Validación cruzada en el tuning

Durante el ajuste de hiperparámetros se utilizó **TimeSeriesSplit(3)** con scoring **average_precision**. Los folds respetan el orden temporal dentro del sub-conjunto de tuning. Mejor PR-AUC en CV: **0.6182** (medido sobre el conjunto balanceado de tuning, que tiene proporciones distintas al dataset real — por eso el valor es más alto).

7.3 Estabilidad entre val y test

La comparación de métricas entre val y test confirma que el modelo generaliza correctamente:

Cuadro 10: Métricas del modelo final en VAL vs. TEST

Métrica	VAL	TEST
PR-AUC	0.0784	0.0801
ROC-AUC	~0.815	0.8059

Las métricas en test son coherentes con val (sin caída significativa), lo que indica ausencia de sobreajuste al conjunto de validación.

8 Caso de uso y limitaciones

8.1 Propuesta operacional: mapa de calor de riesgo




Figura 7: Mapa de calor de riesgo predicho — probabilidad promedio por barrio y hora en TEST (Top 20 barrios de mayor riesgo).

El modelo se propone como un **sistema de alerta diaria** para la Secretaría de Movilidad de Medellín:

1. **Entrada:** cada mañana, se alimentan las predicciones del clima del día y el contexto temporal (día de la semana, festivo, etc.).
2. **Proceso:** el modelo calcula la probabilidad de accidente para cada combinación (barrio, hora) del día.
3. **Salida:** un mapa de calor y un ranking Top-N (por ejemplo, Top-100 combinaciones) que operativos de tránsito priorizan para desplegar agentes.

El mapa de calor (Figura 7) muestra que la franja horaria 6h–22h en barrios céntricos (Caribe, Campoamor, La Candelaria) tiene probabilidades superiores a 0.7, mientras las madrugadas (0h–4h) presentan riesgo bajo incluso en los barrios más peligrosos.

8.2 Limitaciones del modelo

1. **Sesgo de reporte:** solo se modelan accidentes registrados oficialmente. Barrios con menor cultura de denuncia o menor presencia institucional están subestimados en el modelo.

2. **Deriva temporal:** cambios urbanos (obras viales, nuevos desarrollos, eventos masivos recurrentes) degradan el modelo con el tiempo. Se recomienda reentrenar cada 3–6 meses con datos actualizados.
3. **Techo predictivo bajo:** el PR-AUC de ~ 0.08 es honesto — la accidentalidad tiene un componente aleatorio fuerte que no puede capturarse sin información adicional (tráfico en tiempo real, eventos, comportamiento vial). El modelo predice riesgo estructural, no accidentes individuales.
4. **Resolución espacial gruesa:** la granularidad de barrio es demasiado amplia para focalizar intersecciones o cuadras específicas.
5. **Calibración de probabilidades:** las probabilidades brutas del modelo no están calibradas (Platt scaling o isotonic regression). El umbral de 0.700 identifica las combinaciones de mayor riesgo relativo, pero el valor numérico no debe interpretarse directamente como $P(\text{accidente})$ en términos probabilísticos absolutos.

8.3 Variables externas que mejorarían el modelo

- **Tráfico en tiempo real:** datos de Waze o Google Maps (densidad vehicular, velocidad promedio por segmento vial).
- **Eventos masivos:** partidos de fútbol, conciertos, marchas, festivales — todos redistribuyen el flujo vehicular.
- **Obras viales y cierres:** información de la Secretaría de Movilidad sobre desvíos activos.
- **Calendario escolar:** entradas y salidas de instituciones educativas generan picos predecibles.
- **Operativos previos:** la presencia de retenes modifica el comportamiento vial en tiempo real.

9 Conclusiones y trabajo futuro

9.1 Conclusiones

1. **El desbalance de clases (1.507 %) define toda la metodología.** La accuracy es una métrica inútil en este problema: un predictor trivial alcanza 98.5 % sin detectar ningún accidente. Las métricas correctas son PR-AUC, F1 y Recall, con umbral ajustado por función de costo.

2. **Las tasas históricas por barrio son la señal dominante**, muy por encima del clima o de las variables temporales simples. En Medellín, el patrón de riesgo por barrio y hora es estable entre años, lo que hace que la historia sea el mejor predictor del futuro.
3. **El balanceo no cambia el PR-AUC, pero sí el comportamiento con umbral fijo**. Esta es una lección metodológica importante: el ranking del modelo es independiente de la estrategia de balanceo; el balanceo solo afecta dónde cae el umbral óptimo. Se eligió undersampling 3:1 por velocidad y practicidad operacional.
4. **HistGradientBoosting tuned es el modelo final** por su combinación de PR-AUC, velocidad, early stopping nativo y compatibilidad con reentrenamiento frecuente.
5. **La validación es honesta**: partición temporal estricta, umbral elegido en val y test evaluado una sola vez. Las métricas en test (PR-AUC=0.0801, ROC-AUC=0.8059) son consistentes con val, confirmando generalización.
6. **El caso de uso es operacionalmente viable**: el mapa de calor diario permite priorizar recursos de forma sistemática, con una ganancia demostrable frente a la asignación aleatoria.

9.2 Trabajo futuro

1. **Integración de flujos en tiempo real**: Incorporar las variables sugeridas (tráfico satelital y eventos masivos) mediante arquitecturas de streaming de datos para dinamizar el mapa de riesgo de la Secretaría de Movilidad.
2. **Calibración de probabilidades**: Implementar métodos de regresión isotónica o escalado de Platt para transformar las puntuaciones brutas del modelo en probabilidades calibradas reales.
3. **Modelos de granularidad fina**: Migrar el análisis espacial desde el nivel de barrio hacia celdas geográficas regulares (e.g., H3 de Uber) o tramos de vías específicos para intervenciones tácticas más precisas.